赵熙唯

13951001663（微信同号） | zhaoxw1993@163.com | ● AI Agent 应用开发工程师 · 上海

南京理工大学 · 全日制硕士 · 通信与信息系统 | 安徽大学 · 全日制本科 · 电子信息系统

核心亮点

- 4 年 LLM/Agent 工程实践，自研 agent harness（loop / 工具协议 / 记忆 / 子 Agent 编排 / Eval）不依赖 LangGraph 等框架
- 京东 2 年内容审核 NLP 工业级生产经验，覆盖情感分析、谩骂检测、音频查重，日常与大促零积压
- toC AI 产品已盈利：织词 AI 上线 App Store，2000+ 付费用户，独立完成产品/开发/运营全流程

工作经历

独立开发者 / AI产品工程师

2022.07 — 至今

全职独立开发，专注 AI 产品全栈实践与 agent 工程，覆盖 iOS、桌面端、Web 全栈与微信小程序。代表作 **织词 AI**（iOS 多模态英语学习应用，App Store 已盈利、2000+ 付费用户）与 **Travel Agent Pro**（自研 agent harness 的全栈旅行规划系统，pytest 1692 用例）；详见下方项目经历。

京东零售（上海 · 平台业务中心 · 平台业务研发部）

2020.07 — 2022.07

算法工程师

负责京东内容审核平台的文本机审能力建设及部分工程系统开发。独立开发并上线情感分析、谩骂检测、音频查重等算法服务；参与视频/音频异步机审平台的架构设计与开发（Kafka异步架构、任务调度）；保障日常运营和大促期间系统稳定运行。

项目经历

Travel Agent Pro — AI旅行规划Agent

开源 独立开发

2025.10 — 至今

项目负责人 · Agent Harness 设计 / 上下文工程 / 全栈实现

全栈agentic旅行规划系统，后端自研agent harness承载长程多阶段规划任务，前端通过SSE流式渲染推理过程、工具调用轨迹、子Agent进度与记忆召回；通过任务状态机、token高效工具协议、上下文工程（上下文压缩 + 笔记外置 + 按需召回）与LLM-as-judge评测，把开放式规划任务收敛到可观察、可回滚、可评估的工程边界内。

系统架构与关键实现

- Agent Loop：自研think-act-observe主循环，支持流式响应、多轮工具调用、多模型function calling、断点续跑、轨迹回滚与中断恢复
- Token高效工具协议：基于schema声明入参与返回，按阶段裁剪工具集压缩token；区分read/write权限，写操作自动校验、持久化并同步前端
- 上下文工程：分层管理长期、短期与经验记忆，通过规则门控 + 向量检索 + rerank按需召回；结合compaction与external memory跨窗口续接长程任务
- 子Agent并行编排：将复杂规划拆为独立子任务并发执行，仅回传摘要避免上下文污染；汇总后做一致性校验与统一写入
- 可观测与Agent Eval：用OpenTelemetry记录LLM调用、工具轨迹、状态迁移、记忆命中、token成本与延迟；结合guardrails、硬约束、LLM-as-judge、Golden Eval、E2E与pytest回归评测质量

> Python 3.12 + FastAPI + Pydantic v2 + aiosqlite + React 19 + TypeScript + Vite + OpenTelemetry；后端pytest当前可收集1692个用例，代码开源。

ContentGuard — 企业级智能内容审核Agent

开源 独立开发

2026.04 — 至今

项目负责人 · 京东内容审核经验的Agent化升级

面向toB场景的AI内容审核Agent，将传统规则+模型审核升级为Agent驱动平台。支持文本/图文多模态审核，策略自适应，人机协同复审，完整审计链路。

系统架构

- Orchestrator Agent：分析风险等级，动态编排审核流程（高风险多工具交叉验证，低风险快速规则通道）
- 5个审核工具：敏感词/正则 · LLM语义审核 · 情感/立场分析 · 图文一致性校验 · RAG合规知识库
- 策略引擎：业务规则配置，策略版本管理和热更新
- Human-in-the-Loop：低置信度内容转人工复审，完整决策链路审计

设计亮点

- 三级审核成本控制：规则快筛→轻量模型→LLM深度审核，仅对需语义理解的内容调用LLM
- 全链路trace：每条内容的审核路径、工具调用、耗时、LLM推理过程完整记录

> Python 3.12 + FastAPI + LangGraph + RAG + Docker + OpenTelemetry。asyncio异步架构，支持批量/实时双模式。

织词AI — 多模态英语学习iOS应用 已盈利 独立开发

2024.06 — 至今

项目负责人 · 产品 / 开发 / 运营全流程

基于多模态LLM的AI英语学习应用，已上线App Store，2000+付费用户并实现盈利；独立完成产品设计、UI/UX、开发、上架到用户增长全流程。

- AI图像识别学习：拍照/选图→LLM识别图中物体→生成英语词汇与例句
- AI文章生成：基于用户词汇库与学习水平自动生成个性化阅读材料
- iOS原生：Swift + SwiftUI、MVVM架构、EnvironmentObject状态管理
- 后端：Appwrite（认证/持久化）、StoreKit 2（订阅管理）、系统TTS（美音/英音）

京东内容审核 — 文本机审 NLP 算法体系

2020.07 — 2022.07

项目负责人 · 多个核心算法服务从 0 到 1 上线，日常与大促零积压

- **负面情感检测**（2020.12—2021.02）：UGC/PGC长文本分类（TF-IDF+SVM → Word2Vec+TextCNN / RoBERTa继续预训练+微调）+伪标签迭代/回译增强/Focal Loss；精确率 0.95 / 召回率 0.9，周均客诉 < 5 条
- **评论谩骂检测**（2021.10—2021.11）：三层检测（模糊词典→FastText→RoBERTa仲裁），规则+模型结合降低大模型调用率；精确率 0.9 / 召回率 0.97 / 漏审 < 0.1%
- **音频查重**（2021.12—2022.01）：Landmark音频指纹 + ElasticSearch指纹库 + 自研匹配算法 + Kafka异步架构；日均30万条，未修改抄袭片段识别率接近100%
- **其他**：竞品/静音/空格检测、文本纠错、品牌实体识别、句子通顺检测；视频/音频异步机审平台（Kafka 任务调度）

其他独立开发项目

类Notion桌面笔记应用（Electron + Tab预测 + LLM对话 + 文档RAG） · 习惯打卡微信小程序（长期稳定运行）

技术能力

Agent	agent harness 设计、上下文工程（三层记忆 / 多级召回 / compaction）、Agent Eval（LLM-as-judge / Golden Eval）、子 Agent 编排、多模型 function calling（OpenAI / Anthropic）
后端	Python / FastAPI / asyncio / Pydantic v2 / aiosqlite / OpenTelemetry；Kafka / ElasticSearch
前端	React 19 / TypeScript / Vite；Swift / SwiftUI（iOS）、Electron
模型	BERT / RoBERTa 微调、PyTorch；文本分类 / 实体识别 / 情感分析